四川大學

本科生毕业论文（设计）文献综述

题目 音频增强系统啸叫智能检测和抑制方法

学院 计算机学院

专业 计算机科学与技术

学生姓名 蒲晓阳

学号 2021141460201 年级 2021 级

指导教师 冯文韬

教务处制表

2025 年 3 月 7 日

音频增强系统啸叫智能检测与抑制方法的研究

计算机科学与技术

学生 蒲晓阳　　指导老师 冯文韬

[摘要] 声音作为信息传递的重要媒介，而扩音系统作为常见的技术，广泛应用于各种场合中。然而，啸叫现象是扩音系统中常见的问题，常常出现在以体育场、教室以及大型演出为主的场所中，严重的啸叫不仅会影响音质，破坏听感，而且可能破坏扩音系统的元器件，损坏设备。随着扩音系统的广泛应用，抑制啸叫也成为扩音系统的一个重点，因此研究有效的啸叫抑制解决方案具有意义。传统的啸叫抑制方法，如相位调制法、增益控制法和自适应反馈抵消法，虽然已经得到了广泛应用，但其仍存在音质损失和系统鲁棒性差等问题。近年来，随着深度学习技术的突飞猛进，其在各个领域的应用拓展也不断出现，已经有相关研究提出了基于深度学习的音频啸叫抑制技术方案。本文聚焦与音频增强系统中的啸叫智能检测与抑制技术的研究，通过分析声学正反馈的震荡机制以及啸叫现象的声学特点，评估现有的啸叫抑制算法的性能和系统鲁棒性，引入深度学习的方法来改善传统算法的问题，探索深度学习技术在啸叫抑制中的潜力，本文将啸叫抑制建模为监督学习问题，分析对比卷积神经网络（CNN）或者带有注意力机制的递归神经网络（RNN），期望建立啸叫信号和干净信号之间的映射关系，以去除麦克风输出信号中的啸叫分量，从而避免啸叫的发生。

[主题词]： 扩音系统、啸叫抑制、监督学习、深度神经网络

目　录

1 绪论 1

1.1 研究背景和意义 1

1.2 国内外研究现状 2

1.2.1 啸叫抑制技术的研究与发展 2

1.2.2 深度学习技术国内外研究现状 3

2 相关理论简介 4

2.1 声学啸叫的数学模型 4

2.2 时频特征提取 5

2.3 循环神经网络 6

3 总结 7

参考文献 8

1 绪论

1.1 研究背景和意义

声音作为信息传递的常见媒介之一，随着声音在信息传递中的广泛应用，扩音系统成为了确保信息在各类场景下正常传递的重要工具，广泛应用于学校、体育场、教室、大型演出、商场等场景[1][2]。然而，扩声系统在室内使用时，由于扬声器和麦克风处于同一声场，声音信号经过反射后被麦克风重新拾取，容易引发声学正反馈，即啸叫。啸叫现象不仅严重影响听觉体验，还会对音响设备等器件造成不可逆的损坏，这限制了扩音系统的性能和应用场景。因此，研究扩音系统的啸叫智能检测与抑制方法具有重要的现实意义。

从上世纪到现在，啸叫抑制技术经历了从人工干预到模拟电路控制，再到电子自动控制的发展历程。目前的技术主要分为硬件方案和软件方案：其中硬件方案通过优化麦克风和音响的布局与设计来减少啸叫的发生；而软件方案则通过移频/移相、陷波抑制和自适应反馈抑制算法等手段破坏声场中的反馈回路，从而达到抑制啸叫的目的。尽管这些技术已经广泛应用于扩音系统，但随着对人们系统鲁棒性和音质要求的不断提高，现有技术仍暴露出诸多不足。例如，传统自适应反馈抑制算法在处理高相关性信号时收敛速度慢且误差变大，而加入去相关性技术又会导致音质下降[3]。

近年来，人工智能技术的快速发展为啸叫抑制提供了新的思路。基于深度学习的音频处理技术兴起与应用，为突破传统解决方案的局限性提供了可能。通过建立啸叫信号与干净信号之间的映射关系[4]，深度学习方法能够高效地去除啸叫分量，同时减少原始信号的失真。此外，深度学习技术还具有自适应性强、扩展性好等特点，能够更好地适应不同场景下的啸叫抑制需求。

综上所述，本研究旨在探索深度学习技术在啸叫抑制中的应用潜力，提出一种基于深度神经网络的啸叫智能抑制方法。该方法通过分析啸叫的声学机制，引入深度神经网络模型，训练出一套高效的啸叫抑制模型，以提高扩音系统的鲁棒性和音质表现。本研究不仅有助于解决扩音系统中的啸叫问题，还能为音频增强技术的发展提供新的理论和实践参考，推动扩音系统在教育、会议、演出、体育场馆等场景中的广泛应用，提升用户体验并保护设备安全。

1.2 国内外研究现状

1.2.1 啸叫抑制技术的研究与发展

啸叫是扩声系统中常见的问题，其产生机理主要与声反馈现象有关。当扩声系统中的扬声器播放的声音信号经过墙壁或其他物体反射后，被麦克风重新拾取，形成一个正反馈闭环回路[4]。如果该系统中某个频率的信号在这一闭环回路中满足奈奎斯特稳定准则，即环路增益大于等于 1 且相位满足正反馈条件，该频率的信号就会不断放大，形成自激振荡，最终产生刺耳的啸叫声。

在早期，啸叫抑制主要依赖于人工干预，例如通过专业音频人员手动调整均衡器来降低啸叫频点的增益，或者通过改变扩声系统的布局来减少声反馈。这种方法需要专业人员操作，且成本较高，难以实时应对啸叫的产生。随着数字信号处理技术的发展，自动控制方法逐渐取代了手动控制。这些方法通过自动化的算法来检测和抑制啸叫，无需人工干预。

相位调制法：最早出现的自动控制方法之一是相位调制法，包括移频和移相技术。通过改变信号的频率和相位来破坏啸叫产生的相位条件，从而抑制啸叫。虽然该方法简单易实现，但会导致信号失真，对音质有一定影响。

增益控制法：增益控制法[5]通过降低系统增益来减小啸叫信号的强度。自动增益控制（AGC）和自动均衡控制（AEQ）是其中的典型方法。AGC 的方案是当系统检测到啸叫信号时，自动降低整个信号的增益。这种方法比较简单，但会影响整体信号的响度和音质，尤其是在较大的空间中。AEQ 则通过将音频信号分为多个频带，针对特定频段进行增益控制。它能减少对非啸叫频段的影响，从而在一定程度上保持音质，但在检测精度上受到限制。而陷波器法（NHS）是使用陷波器对反馈产生的特定频率点进行抑制，从而消除啸叫。陷波器可以精确地抑制啸叫频点，减少对周围频率的干扰。然而，陷波器的设计和啸叫频点的检测精度是决定其效果的关键。

自适应声反馈抵消法（AFC）：目前较为先进的啸叫抑制技术之一[6]。该方法通过自适应滤波器对声反馈路径进行建模和估计，从而从输入信号中去除声反馈信号，达到抑制啸叫的目的。自适应滤波器的性能取决于其算法和参数。例如，最小均方误差（LMS）算法和归一化最小均方误差（NLMS）算法被广泛应用于自适应声反馈抵消。近年来，研究人员还提出了多种改进的自适应算法，如变步长 LMS 算法，以提高算法的收敛速度和稳态性能。自适应反馈消除法能够有效地消除啸叫信号，但其关键在于反馈路径的精确估计。由于系统中的信号相关性较强，自适应算法需要采用去相关技术，这会导致音质的下降。[5]

1.2.2 深度学习技术国内外研究现状

深度学习的发展历程从 20 世纪 40 年代开始，经历了多个重要阶段。从首个神经元模型到多层感知机的出现。再到反向传播算法（BP）的发明解决了其训练问题，Hinton 等人提出深度学习概念，解决了深度神经网络的训练难题。2010 年后，深度学习在图像识别、自然语言处理等领域取得突破，CNN 和 Transformer 等架构成为重要里程碑。近年来，深度学习在图像处理、语音识别、自然语言处理等领域不断拓展应用，取得了显著的成果。

卷积神经网络（CNN）是一种深度学习模型，广泛应用于图像处理，其特别擅长处理网格化的数据（如图像和视频）。CNN 的核心思想是通过卷积层对数据进行局部感知，从而提取出不同层级的特征。网络结构通常包含卷积层、池化层、全连接层等，用于学习数据中的空间层次结构。尽管 CNN 最初用于图像处理，但鉴于其局部感知和空间特征提取的能力，CNN 也可被用于音频处理。因音频信号通常会通过时频变换转换为矩阵数据，这样 CNN 可以像处理图像一样提取音频信号的空间特征。例如，CNN 可以被用于去噪和语音增强的任务中，可以从混杂的音频信号中分离干净的语音。因此，我们认为其也可以应用于啸叫抑制技术内。

循环神经网络（RNN）是一类用于处理时序数据的神经网络模型。模型能够处理时间序列中的时间相关性，即网络中的节点与先前的状态相关，使其能够保留之前信息并通过循环连接传播信息，这使其特别适合处理语音、文本、视频等序列数据。RNN 被广泛应用于语音识别、音频生成、音频分类等任务中。特别是在语音识别任务中，RNN 可以通过其隐变量的动态变化，建模出语音信号中的时序特征。 RNN 可以用于在嘈杂环境中增强语音，利用时序信息去除背景噪声。通过学习时序数据中的长期依赖关系，RNN 能够从带噪的语音信号中恢复出清晰的语音。在啸叫抑制方面，RNN 可以通过学习音频信号中的时间依赖性，识别啸叫信号的时序特征。RNN 特别适合处理带有回声和延迟的音频信号，这对于抑制啸叫中的回音效应非常有效。RNN 可以学习输入信号的历史信息，捕捉信号中的啸叫模式，实时进行抑制。

Transformer 模型是一种基于自注意力机制的深度学习模型，最早用于自然语言处理（NLP）任务。与 RNN 和 CNN 不同，Transformer 不依赖于序列数据的时序性，而是通过自注意力机制对输入数据进行加权求和，从而捕捉序列数据中不同位置之间的关系。Transformer 的成功不仅限于 NLP 领域，它在音频信号处理，尤其是语音和音乐生成领域也展现出了巨大的潜力。Transformer 的自注意力机制可以使模型对长时间依赖关系建模更为高效，尤其在处理长时间音频时，Transformer 相比 RNN 具有更好的性能。在语音识别任务中，Transformer 通过处理长时依赖关系，提高了识别准确率。在音频分离中，Transformer 能够准确区分混合音频中的不同声音源，提高语音增强效果。在啸叫抑制中，

Transformer 模型可以通过对输入信号进行全局自注意力分析，捕捉啸叫信号的频率和时间特征，并将其从输入信号中去除。Transformer 的高效长距离依赖建模能力使其在复杂的啸叫信号处理中具有优势，能够更好地处理反馈信号的复杂性。

2 相关理论简介

2.1 声学啸叫的数学模型

在不失普遍性的前提下，我们抽象出一个典型的单通道闭环声学放大系统[4]，如图表 1 所示，系统由一个麦克风，功率放大器和扬声器组成。在图中，$v(t)$和$x(t)$分别表示源声信号和扬声器的反馈信号，麦克风把采集到的源信号和反馈信号转化为电信号，得到的麦克风输出信号$y(t)$，之后输出到功率放大器，经过功率放大器 G 进行声学放大后的得到扬声器信号$u(t)$，扬声器负责把电信号转化为声音信号播放出去。扬声器的输出信号通过反馈路径 F 与源声信号$v(t)$产生耦合。$v(t)$近端声音信号，$u(t)$是远端播放信号。

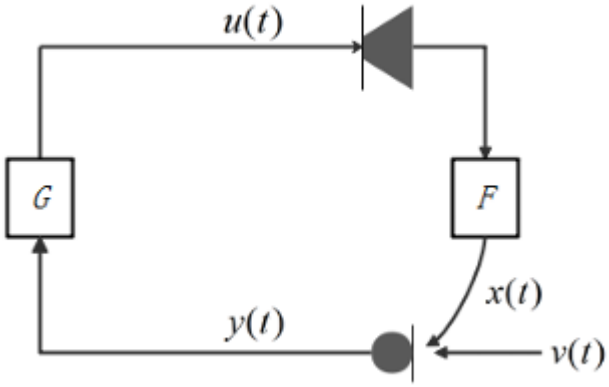

图表 1 单通道闭环扩音系统

因此，声音的传播过程可以以下面的数学式表示：

$$u(t) = y(t) * G(t), \qquad x(t) = u(t) * F(t), \qquad y(t) = x(t) + v(t)$$

其中 * 表示卷积运算，反馈信号$x(t)$为远端扬声器信号$u(t)$和反馈路径脉冲函数 F 卷积产生，扬声器信号$u(t)$ 是由功率放大器的冲激响应函数 G 和麦克风输出信号$y(t)$ 卷积产生。

组合以上公式可以得到麦克风输出信号$y(t)$的数学式：

$$y(t) = \big(y(t - \sigma t)\big) * G * F + v(t)$$

其中，σt表示从麦克风到扬声器的系统延迟，G 表示增益，$y(t)$和$y(t-\sigma t)$之间的递归关系会导致反馈信号的重新放大，以此形成正反馈，导致在某些频率下的循环放大，形成声学啸叫。

我们提出的方法是训练一个深度神经网络训练一个用于抑制啸叫的模型。假设该模型经过一定的训练，其应该衰减麦克风输出信号$y(t)$中的反馈信号$x(t)$，只向扬声器发送目标信号$v(t)$。在模型训练下的声信号传递公式应是：

$$y(t) = \big(v(t-\sigma t)\big) * G * F + v(t)$$

通过训练，反馈信号$x(t)$应该是仅受$v(t)$影响的信号。

2.2 时频特征提取

在计算机中，音频信号通过数字化技术从连续的模拟信号转换为离散的数字信号，音频的数字化过程首先是以固定的时间间隔（采样率）记录模拟信号的瞬时幅度值，常见的采样率有 44.1 kHz（CD 标准）、48 kHz（影视音频）、96 kHz（高保真录音）；其次是量化，将每个采样点的模拟幅度值映射为离散的数字值，数字有深度的概念，常见的有 16 位，24 位和 32 位；最后是编码存储采样后的值。而这样的表示为时频表示，音频信号里隐藏了各种频率的信号，为了能将信号输入到神经网络中，需要将时频信号进行一定的变换提取，常见的提取有频谱表示，梅尔频谱和 MFCC 技术。

频谱表示的提取一般使用的是短时傅里叶变换（STFT），STFT 一般是将信号进行分帧，对每一帧进行傅里叶变换（FFT）生成短时的频谱，再将不同帧的频谱组合形成时频表示，该技术将音频信号分解为时间和频率的二维能量分布，能直观表示信号不同时刻和频率的分量。常用为语音增强特征，但其数据维度较高。

梅尔频率倒谱系数（MFCC）是基于人类听觉特性实现的，把自然频率转化为梅尔频率，符合人类听觉特性。其转换公式如下：

$$MEL(f) = 2595 * log_{10}(1 + \frac{f}{700})$$

其中的 f 是实际信号频率。

梅尔倒谱系数的实现首先对时域信号进行 STFT，将得到每一帧信号的频谱$X(n,k)$通过梅尔滤波器组，得到梅尔频谱。其对信号的降维作用好，对语音特征高度敏感，广泛用于语音识别。但其对高频噪音敏感。

Gammatone 倒谱系数（GFCC）的提取过程与 MFCC 差不多，只是滤波器组不一样，在 Gammatone 倒谱系数中叫做 Gammatone（GT）滤波器组，GT 滤波器相比于梅尔滤波器抗干扰性更强。

2.3 循环神经网络

现代常见的神经网络结构主要有多层感知机（MLP），卷积神经网络（CNN）和循环神经网络（RNN）。其中 RNN 主要用于处理时序结构数据，因此其非常擅长解决音频相关问题，因此本节主要介绍 RNN 的网络结构。

循环神经网络是一种具有隐藏状态的神经网络，其核心特点是能够通过“记忆”历史信息来处理前后依赖的时序任务。与传统的神经网络不同的是，RNN 的神经元之间形成了循环连接，允许信息在时间步之间传递；每个时间步接收当前输入和前一时刻的隐藏状态，输出结果并更新隐藏状态，以形成动态记忆。

假设在时间步 t 时有小批量输入$X_t \in R^{n\times d}$，有用$H_t \in R^{n\times d}$表示时间步 t 的隐藏变量，模型保存了前一时间步的隐藏变量H_{t-1}，引入了一个新的权重参数$W_{hh} \in R^{n\times d}$来描述如何使用隐藏变量。具体而言，当前的隐藏变量的计算公式为：

$$H_t = \emptyset(X_t W_{xh} + H_{t-1} W_{hh} + b_h)$$

其中与全连接层的网络相比，多了一项，从而捕获保留了序列知道当前时间步的历史信息，就如同记忆一样，因此这类的隐藏变量被称为隐状态。由于在 t 时间中，隐状态的定于与前一时间步相关，因此是循环的。于是基于循环计算的隐状态神经网络被称为循环神经网络。在该网络中执行循环计算的层被称为循环层。

对于这样定义的网络中，其输出层类似于多层感知机中的计算

$$O_t = H_t W_{hq} + b_q$$

RNN 的优势在于直接建模序列的时序依赖关系，适应变长输入。常见的变体 RNN 有门控循环单元（GRU）、长短记忆网络（LSTM）和双向 RNN 等。但 RNN 会存在梯度爆炸/消失，计算效率较低等问题，限制了其有效率。

3 总结

本文主要综述了扩音系统中的啸叫的智能抑制方法。传统的抑制方法有包括移频移相技术、陷波滤波、增益控制以及自适应反馈抑制等。然而这些方法在提高系统鲁棒性和音质方面仍然存在局限，存在信号失真、处理高相关性信号时收敛速度慢等问题。

随着深度学习的快速发展，使得应用深度神经网络处理音频啸叫成为了一种可能的选项。卷积神经网络（CNN）能够提取音频信号的空间特征，循环神经网络（RNN）可以学习音频信号的时间关系，而 Transformer 模型则擅长捕捉长距离依赖，提高啸叫信号的检测与抑制能力。因此，本文希望通过深度学习方法[7][8]，建立一种能够高效去除啸叫分量并减少原始信号失真的模型，以提升扩音系统的性能。

总体而言，本研究旨在使用深度学习技术，提出一种智能的啸叫抑制方案，以提升扩音系统的音质和鲁棒性，使其在教育、会议等场景中得到更广泛的应用。

参考文献

[1]周璐.影响自适应反馈抵消啸叫抑制算法性能的声学因素分析[D]. 南京大学, 2012.

[2]杨阳. 声学系统中反馈抑制器的研究和DSP实现[D]. 广州大学, 2016.

[3]王凤森.扩声系统中啸叫抑制算法的研究[D]. 五邑大学, 2020.

[4]甘华国.基于深度学习的音频啸叫处理方法研究[D]. 广州大学, 2021.

[5]Edgar Berdahl and Dan Harris, “Frequency shifting for acoustic howling suppression,” in Proceedings of the 13th International Conference on Digital Audio Effects, Graz, Austria, 2010, vol. 610.

[6]Guozheng Wang, Quanli Liu, and Wei Wang, “Adaptive feedback cancellation with prediction error method and howling suppression in train public address system,” Signal Processing, vol. 167, pp. 107279, 2020.

[7]H. Zhang, M. Yu and D. Yu, "Deep Learning for Joint Acoustic Echo and Acoustic Howling Suppression in Hybrid Meetings," 2023 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU), Taipei, Taiwan, 2023, pp. 1-7

[8]H. Zhang, M. Yu and D. Yu, "Deep AHS: A Deep Learning Approach to Acoustic Howling Suppression," ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Rhodes Island, Greece, 2023, pp. 1-5