DeepL
订阅DeepL Pro以翻译大型文件。
欲了解更多信息，请访问www.DeepL.com/pro。

arXiv:2309.16048v1 [eess.AS] 2023年9月27日

通过神经网络递归训练推进声学嚎叫抑制

Hao Zhang[1]* , *Yixuan Zhang*[2)]* , *Meng Yu*[(1(], *Dong Yu*[1]

[1]腾讯人工智能实验室，美国华盛顿州贝尔维尤市
[2] 俄亥俄州立大学，美国俄亥俄州哥伦布市

摘要

本文介绍了一种新型训练框架，旨在通过研究声嚎叫的全面解决声嚎叫问题基本形成过程，。该框架在训练过程中将神经网络（NN）模块到闭环系统中，集成并通过实时递归生成的信号密切模拟声学嚎叫抑制（AHS）的。流过程我们提出的递归训练策略弥补了训练与之间的差距实际推理场景，这标志着我们与以往基于 NN 的方法不同之处的，后者通常将 AHS 视为噪声抑制或声学回声消除。在这一框架内，我们探索了两种方法：一种方法方法是完全依赖 NN 的，另一种是将相结合NN 与传统卡尔曼滤波器。的此外，还我们提出了一些策略，包括使用预先训练好的离线模型初始化，以提高可训练性并加快进行嚎叫检测和训练过程。实验结果证明，与相比，以前的声学嚎叫抑制方法。该框架有了很大改进

索引词条--AHS、递归训练、卡尔曼滤波器、深度学习

1. 引言

声学嚎叫是一种源于的现象音频系统本身正反馈，通常是由于输出放大声音引起的扬声器的被麦克风拾取并随后重新放大而[1, 2, 3]。这就形成了一个不受控制的正反馈回路，导致特定被不良放大频率成分，并产生持续而难听的声。这种现象通常出现在中助听器、公共广播系统和卡拉 OK 等。系统嚎叫声的存在不仅对设备的功能构成威胁，还对人类听力系统构成潜在风险。

针对声学嚎叫提出了许多方法抑制（AHS），包括增益控制[4]、频率偏移[[6, 5]、陷波滤波器7]和自适应反馈消除（AFC）[8, 9, 7]。，AFC 方法采用类似卡尔曼滤波器[10] 的，，从而估计消除嚎叫信号，自适应滤波器根据检测到的反馈不断更新滤波器系数和是一种比其他方法。然而，更强大的 AHS 方法AFC 技术对控制参数很敏感，往往会在反馈系统出现出现非线性失真时问题。声嚎叫与声回波类似，因为它们都是引起的由通信系统中的反馈，对声回波会导致处理不当声嚎叫。深度学习已经证明

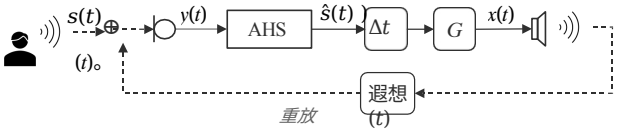

图 1.AHS 系统。的配置

在上处理声学回声问题表现抢眼[11, 12]，最近已成为 AHS 任务的一种有前途的解决方案。Chen 等人[13] 提出了一种用于的深度学习方法嚎叫检测。后来，推出了：两种基于学习深度的 AHS 方法嚎叫噪声抑制 [14] 和深度边际反馈消除（DeepMFC）[15]。这些方法将 AHS 视为噪声抑制任务，训练神经网络 (NN) 模块直接从离线生成的微型电话中估计目标语音，信号而不结合 AHS 处理。一种与众不同的方法，即 DeepAHS [16]，利用教师强迫学习，与之前的方法相比表现出更优越的性能。在 DeepAHS 的基础上，HybridAHS [17] 通过将卡尔曼滤波器的输出作为模型训练的额外输入，。进一步增强了嚎叫抑制能力尽管取得了这些进步，但目前的方法都坚持离线生成信号训练，导致训练和实时推理之间不匹配，最终削弱了其有效性。

本文通过对神经网络，。具体来说，进行递归训练训练方法介绍了一种用于声嚎声抑制的创新我们利用具有长短期记忆（LSTM）架构的递归抑制装置，对麦克风信号进行逐帧处理神经网络[18]作为 NN 模块，并将其集成到嚎叫的闭环系统中。为实现嚎叫抑制，对 NN 模块进行了训练，以使用复比掩码（cRM）估计法 估计[19]，。从中麦克风信号出目标语音用于模型训练的输入信号是实时递归生成的，以模拟声学嚎叫形成的基本过程过程中，即 NN 在每一帧的都会通过闭环，然后反馈到输出生成其后续输入帧。为了的充分发挥递归训练的优势，我们利用过去处理过的扬声器信号或卡尔曼滤波器的输出作为训练 NN 模块的。参考信号

我们的研究有三大贡献。首先，神经网络的递归训练有效消除了以往基于神经网络的 AHS 方法中存在的不匹配限制，从而提高了性能和鲁棒性。其次，我们探索了在内此框架：一种是两种配置纯粹的基于神经网络的方法另一种是将神经网络与卡尔曼滤波器相结合混合方法，从而，的为设计基于神经网络的 AHS 系统。提供了灵活性

*H. Zhang 和 Y. Zhang 的贡献相同。这项工作是张宇在腾讯人工智能实验室实习时完成的。

第三，我们采用了嚎叫检测和使用预训练模型初始化等策略，以促进递归训练的收敛。第三，我们采用了嚎叫检测等策略和使用预训练模型初始化，以促进递归训练的收敛。

本文的其余部分安排。第 2 节介绍声学嚎叫问题。第 3 节介绍建议的方法。第 4 节和第 5 节分别介绍了。第 6 节为本文的结论。实验装置和结果

2. 声学嚎叫抑制

2.1. 声学嚎叫问题的提出

让我们考虑单通道声学放大系统图 所示的1 。麦克风捕捉到的被传输到扬声器进行声学放大。目标信号 $s(t)$ 放大后的信号 $x(t)$ 由扬声器播放，到达麦克风时为重放信号 ，相应的麦克风信号是目标语音和重放信号的混合信号：$d(t)$

$$y(t)= s(tt)+ x(*h(t) \tag{1}$$

其中∗ 表示线性卷积，$h(t)$ 表示声学从扬声器到麦克风的。路径

在不进行任何 AHS 处理的下，扬声器信号 情况$x(t)$ 将是先前麦克风信号 $y($的放大版本。 −
Δt），并反复重新进入拾音器，从而将麦克风信号表示为

$$y(t)= s(t)+ [y(t -\Delta t) - G]* h(t) \tag{2}$$

其中Δ t 表示从麦克风到系统延迟扬声器的，G 表示放大器增益。在适当抑制嚎叫的情况下，AHS 模块将抑制反馈并输出目标信号的估计值 $s\hat{}(t)$，相应的麦克风信号将为

$$y(t)= s(t)+ [s\hat{}(t -\Delta t) - G]* h(t) \tag{3}$$

$y(t)$ 和 $y(t -\Delta t)$ 之间的递归关系，以及 $s\hat{}(t -\Delta t)$ 中存在的泄漏，可能导致重放信号的再次放大，形成反馈回路，表现为一种不悦耳的高音调声音，即声学嚎叫。

注意到方程 (1) 中 AHS 的表达式与声学回声消除 (AEC) 。的表达式相似但它们在上有所不同来源和特征。嚎叫声与目标信号来源相同，而且是逐渐的，因此与声学回声相比，抑制嚎叫声更具挑战性，因为声学回声通常产生来自不同的来源（远端扬声器），可以作为瞬时语音分离问题来处理。

2.2. 基于 NN 的现有 AHS 方法中的不匹配问题

由于当前输入与先前输出，。之间的依赖关系声学嚎叫的递归性给带来了创建合适的训练信号挑战早期基于 NN 的技术通过来使用离线生成的麦克风信号。具体来说，是训练模型解决 AHS 问题嚎叫噪声抑制和 DeepMFC 等方法利用的离线生成的麦克风信号，没有 AHS，如式 (2) 。所示DeepAHS 和 HybridAHS 采用教师强制学习法，假定嚎叫声得到完美抑制，其中微型电话用于训练的信号是通过将 替换为$s\hat{}(t)$ 等式 中的 (3) 。$s(t)$ 而离线生成的

出现不匹配问题的原因是，真实麦克风推理过程中接收到信号等式 所描述的已评估麦克风信号是利用(3) 递归生成的，与这些方法中使用的训练信号不同。

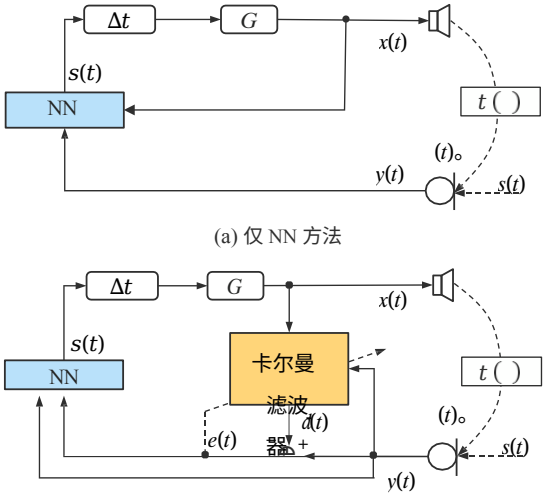

图 2.拟议方法的(a) 仅使用 NN 的方法，(b) 混合方法。示意图

算法 1 针对 AHS 的 。NN 的递归训练

程序 STREAMING((**Y**, **R**)→ $\hat{S}$) ▷**R**：参考信号 随机
初始化或加载预训练的 NN 模型：NN(-)
随机生成：Δ t、G
while $m \le M$ **do** ▷M 是帧的总数 $\hat{S}_m \leftarrow$ NN(Y_m, R_m) ▷ 第 m 帧的输出
$X_m \leftarrow$ 延时 $\hat{S}_m - G$
$\mathbf{Y}_{m+1} \leftarrow \mathbf{S}_{mm+1)} + \mathbf{X}_{(} - \mathbf{H}$ ▷更新麦克风信号
如果采用混合法，**则** ▷ 更新参考信号
$\hat{D}_{m+1} \leftarrow \mathbf{K}(\mathbf{Y}_{mm)+1}, \mathbf{X}_{(})$ ▷K(-): 卡尔曼
$R_{m+1} \leftarrow E_{m+1} = Y_{m+1} - \hat{D}_{m+1}$
否则（NN 仅方法）
$R_{m+1} \leftarrow X_m$
如果结束
$\tilde{S} \leftarrow \hat{S}_m$ ▷将到处理过的帧保存最终输出
同时结束
损耗← (**S**, $\hat{S}$) ▷获取损耗
NN(-)← *Loss* ▷更新 DNN 参数
结束程序

3. 建议方法

3.1. 整体系统

采用递归训练法是为了缓解匹配错误问题，并整个过程中训练和转换。在这里，保持一致性输入信号是在模型训练过程中，其中每个处理过的帧都作为后续帧的输入，从而保持了嚎叫抑制固有的递归性质。递归生成的受先前研究的启发，我们研究了配置，配置我们提出的方法中的如图 2 。所示，这些采用了单独的 NN 和带有卡尔曼滤波器的来实现 混合 NN AHS拟议的方法是在频域中我们在图中使用了时域标签，以澄清信号关系并提高理解度。实现的，而算法 1 ，其中 提供了拟议方法的更多细节NN(-) 和 K(-) 分别代表 NN 模块和卡尔曼模块的参数。

3.2. 模型培训

3.2.1. 仅 NN 方法

纯 NN 方法将频域麦克风信号 Y_m 和参考信号 R_m 作为输入，以获得目标估计值信号 $\hat{S}_m$ **的** 如算法 1： 所述

$$\hat{S}_m = \mathrm{NN}\ (Y_m,\ R_m) \tag{4}$$

其中，m 表示帧索引，上一帧中的扬声器信号 X_{m-1} 被用作参考信号。

3.2.2. 混合法

混合方法的示意图如图 2（b）。所示该方法将 相结合NN 与传统的卡尔曼滤波器，其中卡尔曼模块通过自适应对声学路径进行建模解决嚎叫抑制滤波器，然后从麦克风记录中得到误差信号 从而减去相应的估计重放信号 $\hat{D}_m$，，问题：E_m

$$\hat{D}_m = K(Y_m,\ X_{m-1}) \tag{5}$$
$$E_m = Y_m - \hat{D}_m$$

然后，卡尔曼滤波器的输出被用作参考信号混合方法中训练 NN 模块的，以获得目标语音的估计值：

$$\hat{S}_m = \mathrm{NN}\ (Y_m,\ E_m) \tag{6}$$

所提出的混合方法可以看作是的递归对 HybridAHS 训练调整[17] 。HybridAHS 使用预处理，与之不同的在时离线训练是，我们的方法将 NN 模块和卡尔曼滤波器集成到闭环系统中，进行逐帧处理。卡尔曼滤波器的信号这种方法充分利用了两个模块的优势，同时有效地解决了 HybridAHS 中的不匹配问题。

3.2.3. 网络结构和损失函数

在中拟议的 NN 模块。我们采用 LSTM 进行复比掩码估计 [19]值得注意的是，我们在中的这项研究主要重点并不是引入新的网络架构；相反，我们提出的方法提供了选择网络结构的灵活性。我们实现中使用的 LSTM 网络由两个组成，隐藏隐藏层每个层有 300 个万个单元，从而产生 154 可训练参数。模型训练的输入是 $[Y, |Y_r|, |Y_i|]$ 的串联，训练目标设定为 $[S_r, S_i]$。 $|*|$,$*_r$ 和$*_i$ 代表幅值、实值和虚值相应频域信号。的频谱图我们使用的帧大小和帧移分别。所有为 8 毫秒和 4 毫秒模型均经过 60 次训练，批量大小为 128。

我们使用语篇级别样本的作为模型训练的损失函数：的实义和虚义平均绝对误差（MAE）

$$\textit{损耗} = \mathrm{MAE}(\hat{S}_r,\ S_r) + \mathrm{MAE}(\hat{S}_i,\ S_i) \tag{7}$$

3.3. 递归训练中的收敛问题

为 AHS 引入 NN 的递归训练带来了挑战，尤其是难以实现收敛。嚎叫生成固有递归的特性会导致信号积累和能量爆炸，超过最大允许值在 Python 中会触发 "非数字"（NAN）警告，从而阻碍梯度计算和模型更新。这个问题在批量训练中尤为突出，因为一个语篇的收敛失败会影响整个批量的损失值。为了应对这一挑战，我们提出了两种策略：嚎叫检测和使用预训练模型进行初始化。

3.3.1. 嚎叫侦测（高清）

一种有效的策略是将嚎叫检测纳入训练过程。在过程中递归训练，我们会持续监测麦克风信号是否出现嚎叫声，嚎叫声的识别方法是麦克风信号的幅度100 个连续样本中。持续超过阈值一旦检测到，就当前语句的进一步处理会停止，只有已经处理过的部分才会被用于计算。将排除损失嚎叫信号在之外，进一步处理和损失计算可以防止潜在的 NAN 问题，并将其对 NN 模块收敛的影响降至最低。

3.3.2. 使用预训练模型进行初始化

我们提出的另一项提高可训练性和减少训练时间的是利用预先训练好的离线模型来初始化 NN 参数。策略通常，NN 模块的参数是随机初始化的，这可能无法保证充分抑制嚎叫，并可能在初始训练阶段。导致严重的嚎叫和 NAN 警告尽管在递归推理场景中情况，但与随机初始化的 NN 模块相比，离线预训练模型仍然表现出更出色的嚎叫抑制能力。不可避免地会出现不匹配的采用离线预训练模型进行 NN 参数初始化可以解决 NAN 问题，并确保模型训练。这种的收敛性方法可视为离线模型。的一种递归微调形式在中我们的实施，我们采用了预先训练好的 HybridAHS [17] 来进行 NN 初始化。

4. 实验装置

4.1. 数据准备

实验使用 AISHELL-2 数据集进行[20]。我们使用生成了 10,000 对房间脉冲响应（RIR）图像法[21]，房间特征和混响时间（RT60）随机选择，在 范围0 到 60 之间。
0.6 秒。每个 RIR 对包括近端扬声器和扬声器位置。的 RIR模型训练按照算法 1 进行。中概述的步骤在过程中训练，对于每个训练样本，我们都会选择一个语音样本和一对 RIR，用于生成目标语音和重放信号。系统延迟Δt 在 内0.15 秒秒至 0.25 的范围随机生成，而放大增益 G 则在 内1 至 3 。的范围随机选择

我们使用的训练、验证和集集集测试分别。包含 38,000 个、1000 个和 200 个语句与训练和验证相比，测试数据使用了不同的语料和 RIR。

4.2. 评估指标

在评估 AHS 性能：信号失真时，使用了两个以表示指标*平均值± 标准偏差*的比（SDR）[22] 和语音质量感知评估（PESQ）[23]。鉴于 PESQ 对规模，不敏感，我们强调 SDR 结果展示抑制嚎叫的效果，同时依靠 PESQ 评估语音质量。

表 1.不同嚎叫抑制。方法的流式评估

机型	SDR （分贝）				PESQ			
G	1.5	2	2.5	3	1.5	2	2.5	3
无 AHS	-30.51± 7.23	-31.86± 5.66	-33.10± 3.96	-33.21± 3.94	-	-	-	-
卡尔曼滤波 [10]	-5.11± 13.20	-10.33± 14.84	-14.88± 15.14	-18.25± 14.77	1.94± 0.72	1.65± 0.73	1.44± 0.70	1.30± 0.64
DeepMFC [15]	-0.09± 6.50	-2.78± 9.44	-5.59± 11.40	-7.69± 12.26	2.11± 0.51	1.88± 0.59	1.70± 0.62	1.56± 0.59
HybridAHS [17]	2.96± 3.04	1.25± 5.79	-1.45± 9.60	-3.49± 10.90	2.57± 0.47	2.33± 0.53	2.22± 0.59	1.95± 0.62
建议的 NN	3.70± 1.70	2.85± 1.45	2.34± 1.26	1.99± 1.05	2.50± 0.43	2.28± 0.39	2.12± 0.36	2.00± 0.34
建议的混合动力（RM）	2.95± 2.02	1.92± 1.70	1.28± 1.47	0.84± 1.30	2.56± 0.40	2.35± 0.36	2.21± 0.34	2.11± 0.32
建议的混合动力	**3.87± 1.68**	**3.04± 1.34**	**2.49± 1.11**	**2.11± 0.98**	**2.60± 0.41**	**2.40± 0.38**	**2.25± 0.36**	**2.13± 0.34**

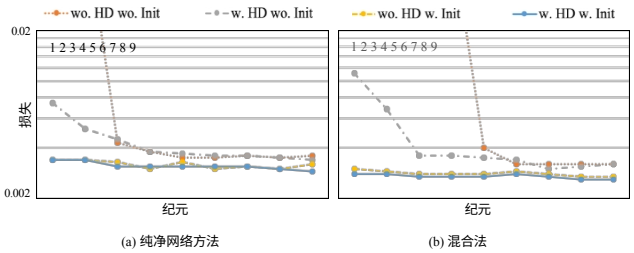

图 3.拟议方法的。收敛性探索

5. 实验结果

5.1. 融合探索

我们首先评估了我们提出的策略有效性在递归训练过程中实现收敛的。图 显示了前几个历元的损失值。3 在不采用任何策略的情况下，由于上述，收敛性无法得到保证NAN 问题。采用 HD 策略成功完全规避了这一问题，确保了模型的可训练性。此外，使用预先训练好的模型（HybridAHS）对 NN 模块进行初始化，可大大提高模型的收敛性。

5.2. 嚎叫抑制性能

我们将所提出的方法与卡尔曼滤波法AHS 方法在不同的放大增益 (和基于 NN 的 *G*) 水平下进行了，结果见表 比较1。图 提供了4 。在下中度和重度嚎叫场景评估的测试语音的频谱图所有基于 NN 的方法都采用了相同的网络结构和数据集，以便进行公平比较。值得一提的是，拟议的递归训练需要更长的训练时间，但推理时间与使用离线训练的基线方法相同。

在没有任何嚎叫声抑制（"无 AHS"）的情况下，麦克风信号的平均 SDR 值低于 30 dB，这表明嚎叫声占主导地位，可辨语音。几乎可以忽略不计因此，在这种情况下计算 PESQ 值就显得多余了。

与 "无 AHS "情况相比抑制。，利用卡尔曼滤波器可以显著嚎叫转而采用基于 NN 的 AHS 方法（DeepMFC 和 HybridAHS）后，嚎叫抑制。效果大幅提升我们提出的方法在 SDR 方面始终优于基线方法，特别是在较高的 *G* 级。在 PESQ 结果，方面我们的方法方法在较低 与 HybridAHS 具有可比性*G* 值时值时。值得注意的是，，而优于基线在则较高 *G* 我们的混合方法在性能上超过了纯 NN 方法。

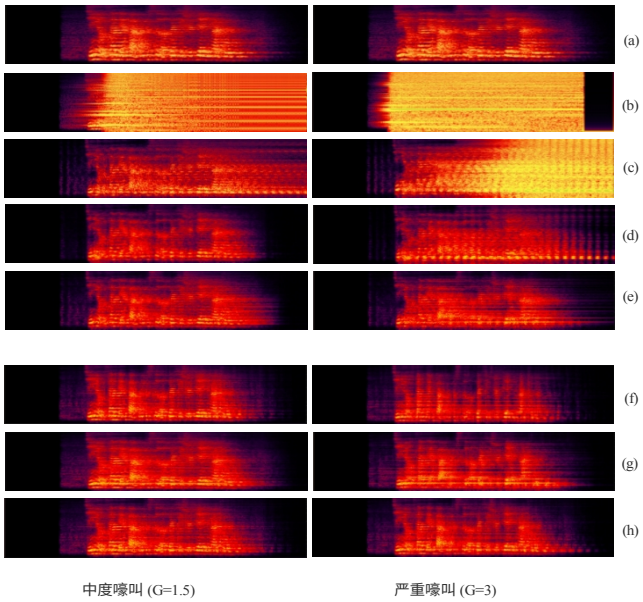

图 4.以下的(a) 目标信号，(b) 无 AHS，(c) 卡尔曼滤波 信号频谱图[10]，(d) DeepMFC [15]，(e) HybridAHS [17]，(f) 拟议 NN，(g) 拟议 Hybrid (RM)，以及 (h) 拟议 Hybrid。（演示见 https://yixuanz.github.io/AHS 2023 1）。

为了进行比较，我们还使用比率掩码估算（RM）实现了所提出的混合方法。如图 所示，复数域估计可有效减少增强信号中的回放泄漏，从而提高 AHS 性能。4(g)和(h)加入

此外，，我们提出的递归训练方法显示出我们的方法与离线训练的基线相比低的标准偏差方法更，这表明具有更高的稳定性和持续的嚎叫支持。

6. 结 论

在本研究中，我们为基于 NN 的自动语音合成系统引入了一种递归训练方法，利用嚎叫检测和预训练模型初始化来提高模型的可训练性。我们的方法在纯 NN 和混合配置中都得到了应用。所提出的方法成功地解决了以往基于 NN 的自动语音合成技术中出现的不匹配问题，从而在保持语音质量的同时实现了出色的嚎叫抑制效果。这项研究为嚎叫抑制领域做出了显著贡献。未来的研究方向包括探索其他递归训练策略，以及将我们的方法扩展到多通道自动语音合成系统。

7. 参考文献

[1] Richard V Waterhouse, "Theory of howlback in *the*reverberant rooms," *The Journal of the Acoustical Society of America*, vol. 37, no.5，第 921-923 页，1965 年。

[2] Toon Van Waterschoot 和 Marc Moonen，"五十年声反馈控制：99, no. , pp.

[3] W Loetwassana, R Punchalard, , A Lorsawatsiri, J Koseeyaporn, and P Wardkein, pp"Adaptive howling suppressor in an audio amplifier system," , in *2007 2007Asia-Pacific Conference on Communications*. IEEE.IEEE，2007 年，第 445-448 页。

[4] Manfred R Schroeder，"改善通过频率偏移能力"，声反馈*美国声学学会杂志》*，第 36 卷，第 9 期，第 1718-1724 页，1964 年。

[5] 埃德加-伯达尔和丹-哈里斯："频率抑制声嚎叫的"，偏移《*第 13 届国家间数字音频效果会议论文集》，奥地利格拉茨，*2010 年，第 610 卷。

[6] Pepe Gil-Cacho、Toon Van Waterschoot、Marc Moonen 和 Søren Holdt Jensen"抑制"用于声学的正则化自适应陷波滤波器嚎叫，*2009 年第 17 届欧洲信号处理会议*。IEEE，2009 年，第 2574-2578 页。

[7] Toon van Waterschoot 和 Marc Moonen，"比较基于陷波滤波器的嚎叫抑制"，《中嚎叫检测标准的评估*音频工程学会期刊》*，第 58 卷，第 11 期，第 923-940 页，2010 年。

[8] Harry Alfonso L Joson、Futoshi Asano、Yo' Suzuki 和 Toshio Sone，"用于助听器的频率压缩"，自适应反馈消除*美国声学学会杂志》*，第 94 卷，第 6 期，第 3248-3254 页，1993 年。

[9] Felix Albu、Linh TT Tran 和 Sven Nordholm："用于自适应反馈消除"，的混合简化卡尔曼滤波器*2018 年国际通信会议（COMM*）。IEEE，2018，第 45-50 页。

[10] Gerald Enzner 和 Peter Vary，"频域用于免提电话回声控制的自适应卡尔曼滤波器"，《*信号处理*》，第 86 卷，第 第 1140-1156 页、6 期，
2006.

[11] Hao Zhang and D Wang, "Deep learning for acoustic echo cancellation in noisyvol. 161, no. 2, pp. and double-talk scenarios," *Training*,

[12] Hao Zhang and DeLiang Wang, "Neural cascade architec- ture for multi-channel *acousticIEEE/ACM* echo suppression" ,*Transactions on Audio, Speech, , and Language Processing*vol. 30, pp.

[13] Zhipeng Chen, Yiya Hao, Yaobin Chen, , Gong Chenand Liang Ruan, "A neural network-based howling detection method for real-time communication applications," in *2022 ICASSP*.IEEE，2022 年，第 206-210 页。

[14] 甘华国、罗高勇、罗雅清、罗文斌年：《利用深度神经网络消除时频域嚎叫噪声》，》，*的《第六届国际论文集第 319-332 信息与通信技术Springer大会*，2022 ，页。Springer, 2022, pp.

[15] Chengshi Zheng, Meihuang Wang, Xiaodong Li, and Brian CJ Moore, "A deep learning solution to the marginal stability problems ofacoustic feedback systems for hearing ids," *The Journal of the Acoustical Society of America,* vol. 152, no. 6、
pp.3616-3634, 2022.

[16] Hao Zhang, Meng Yu, and Dong Yu, "Deep AHS: A deep learning approach to acoustic howling suppression," in *2023 ICASSP*.IEEE, 2023, pp.

[17] Hao Zhang、Meng YuYuzhong 、Wu、Tao Yu Dong Yu，和 "deep learning for acoustic howling suppression"，Hybrid AHS：A hybrid of Kalman filter and *arXiv preprint arXiv：2305.02583*，2023。

[18] 亚历克斯-格雷夫斯和亚历克斯-格雷夫斯，"长期短期记忆"。*利用递归神经网络进行有监督的序列标记*、
pp.37-45, 2012.

[19] Donald S Williamson, Yuxuan Wang, and DeLiang Wang, "Complex ratio masking for monaural speech separation," *IEEE/ACM transactions on audio, speech, and language pro- cessing*, vol. 24, no.3，第 483-492 页，2015 年。

[20] 杜嘉宇、那星宇、刘学臣卜慧：《Aishell- 2：乳将鸳鸯晡研究转化为产业规模》，*arXiv预印本arXiv:1808.10583*，2018。

[21] Jont B Allen 和 David A Berkley，"有效模拟小房间声学的图像方法"，*美国声学学会杂志》*，第 65 卷，第 4 期，第 943-950 页，1979 年。4，第 943-950 页， 1979。

[22] Jonathan Le Roux、Scott Wisdom、Hakan Erdogan 和 John R Hershey，"做得好？"，SDR--半生不熟还是*2019 ICASSP*。IEEE，2019 年，第 626-630 页。

[23] Antony W Rix, John G Beerends, Michael P Hollier, and Andries P Hekstra, "Perceptual evaluation of speech quality (PESQ)-a new method for speech quality assessment of tele- phone networks and codecs," in *2001 ICASSP*.IEEE, 2001, vol. 2, pp.