深度AHS：一种用于抑制声学啸叫的深度学习方法

Hao Zhang, Meng Yu, Dong Yu

Tencent AI Lab, Bellevue, WA, USA

摘要

在这篇论文中,我们将声学啸叫抑制（AHS）表述为一种监督学习问题，并提出了一种名为Deep AHS的深度学习方法来解决这一问题。Deep AHS采用教师强制学习方式进行训练，这将循环啸叫抑制过程转换为瞬时语音分离过程以简化问题并加速模型训练。所提出的方法利用适当设计的特征和一个基于注意力的递归神经网络（RNN）来从麦克风录音中提取目标信号，从而抑制可能导致啸叫的反馈信号。我们研究了不同的训练策略，并在递归模式下实现了流式推理方法，用于评估所提出的实时啸声抑制方法的性能。Deep AHS 避免了啸叫检测的过程，从本质上禁止了啸叫的发生，使得音频系统的设计更加灵活。实验结果表明了所提出的方法在不同场景下抑制啸叫的有效性

关键字 — 啸叫抑制，深度学习，Deep AHS，教师强制学习，流式推理

1. 引言

当存在正反馈时，由于麦克风和扬声器之间的耦合而产生啸叫[1][2]。具体而言，音频系统中的麦克风信号通过暴露在同一空间中的扬声器播放出来，由同一麦克风再次拾取，形成一个封闭的声学回路。如果处理不当，这种反馈信号将被重复播放，并在具有单位或更大环路增益的频率下产生尖锐的声音。这种现象被称为啸叫。啸叫是视频/音频会议以及助听器和卡拉OK等声学放大系统中的一个关键问题。它不仅对我们的听觉系统有害，而且对扩音设备也有破坏性[3]。

人们已经提出了许多声学啸声抑制（AHS）解决方案来解决这个问题，包括增益控制[4][5]、陷波滤波器（NF）[6][7][8]和自适应反馈抵消（AFC）[9]。降低增益的方法可以通过手动降低放大器的音量或改变音频设备的位置来实现。然而，这些方法的应用范围有限，不适合需要高声放大的场景[10]。NF方法通过调整滤波器系数在出现啸声的频率处生成空值来减弱啸叫。然而，NF方法需要对啸叫进行精确的检测，并且会扭曲目标声音，甚至引入意想不到的啸叫频率点[6]。AFC 通过使用自适应滤波器来估计扬声器和麦克风之间的声学路径来抑制啸叫。并且由于目标信号和反馈信号高度相关，AFC方法通常需要使用去相关技术，但这通常会使语音质量失真[11]。

啸叫抑制的最终目标是衰减反馈信号，只将目标信号发送到扬声器，这与我们处理声学回波信号（AEC）的方式基本相同。考虑到深度学习在处理复杂的非线性关系方面具有强大的能力，并且已经成功地被引入到抑制声学回音中[12][13][14][15][16]，因此，它也可以作为解决AHS问题的有力替代方案。Chen等人[17] 提出了一种基于深度学习的啸声检测方法。Gan等人[18]采用深度学习来抑制啸叫噪声。然而，[18]中提出的方法将啸叫视为一种噪声进行语言增强，而不是以流式和循环的方式抑制啸声。

在这片论文中，我们提出一种深度学习发方法。名为Deep AHS，来解决啸叫抑制问题。 我们的方法是将AHS表述为一种监督学习问题，任务总体是在抑制麦克风录音中的反馈信号和背景噪音的同时只保留目标信号。考虑到反馈信号和目标信号高度相关，我们使用输入信号的时间相关性、频率相关性和信道协方差的级联作为特征，并训练基于注意力的递归神经网络（RNN）[19]来估计目标信号的复比滤波器[20]。据我们所知，这是第一项将深度学习用于声学啸叫抑制的研究。这项研究的贡献有四点。首先，Deep AHS将啸叫抑制这一种自适应过程表述为在教师强制学习方式下的监督学习问题。它与传统的AHS方法有着根本的不同，不需要啸叫检测，其次，在这种训练策略下实现了流式推理方法，以循环的方式评估Deep AHS的性能。第三，Deep AHS对非线性失真具有鲁棒性，可以在不同场景下联合实现啸叫和噪声的抑制，允许更高的环路增益，并为音频系统的设计带来灵活性。最后，本研究对不同的训练策略进行了调查和系统比较，以证明我们的方法对啸叫抑制问题下的有效性。

本文的其余部分组织如下。第2节介绍了声学啸叫。第3节描述了我们提出的方法。实验装置和结果分别在第4节和第5节中介绍。第6节为本文的结论。

2. 声学啸叫的理论表述

在不失一般性的情况下，让我们考虑一个典型的单通道声学放大系统，其中麦克风和扬声器耦合在同一空间中，如图1（a）所示。目标语音被麦克风拾取为s（t），然后被发送到扬声器进行声学放大。扬声器信号x（t）被播放出来，并作为播放信号d到达麦克风。

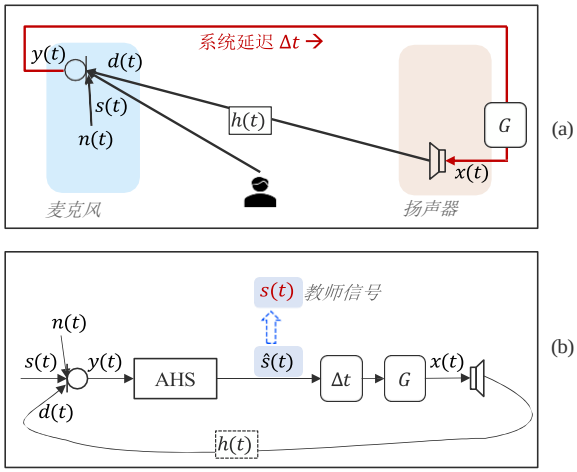

图. 1. (a) 声学放大示意图, (b) 声学啸叫抑制系统信号流示意图

记作d(t):

$$d(t) = NL[x(t)] * h(t) \tag{1}$$

其中 NL(·) 表示扬声器引入的非线性失真，h(t) 表示从扬声器到麦克风的声学路径，∗ 表示线性卷积。

如果不进行任何处理，扬声器x(t) 将是y(t)经过延迟和放大的版本，而这个反馈信号d(t) 将反复进入拾音器，则时间索引t处的相应麦克风信号可以表示为：

$$y(t) = s(t) + n(t) + NL\,[y(t - \Delta t) \cdot G] * h(t) \tag{2}$$

其中n(t)表示背景噪声，Δt表示从麦克风到扬声器的系统延迟，G表示放大器的增益。y(t)和y(t − Δt)之间的递归关系会导致反馈信号的重新放大，并形成正反馈，导致在某些频率下的循环放大，称为声学啸叫。话虽如此，啸叫是以反复的方式产生的，而不是瞬间产生的。它以多个反馈信号开始，在放大到一定程度后逐渐形成尖锐的声音。

值得注意的是，声学啸叫不同于声学回声，尽管处理不当的声学回声（泄露）也可能导致啸叫。两者的主要区别在于：1. 两者本质上都是反馈信号，而啸叫是逐渐产生的。2. 导致啸叫的反馈信号是由与目标信号相同的源产生的，而声学回声通常产生自不同的源（远端的说话者），这使得啸叫的抑制更具有挑战性。

3. 采用的方法: DEEP AHS

3.1. 教师强制学习用于抑制啸叫

理想情况下，如果AHS方法能够完美地处理麦克风录音并在发送到扬声器之前完全衰减其中的反馈信号分量，那么在任何情况下都不会出现啸叫问题。从语音分离的角度来看，AHS似乎可以被视作一个语音分离问题。

其中目标信号 s(t) 是从麦克风信号中分离的源信号，这与基于AEC表述的深度学习思想是类似的。

然而，考虑到在第2节所描述的声学啸叫特性，使用深度学习实现啸叫抑制绝非易事。最关键的问题是这样的，啸叫是自适应产生的，当前的输入取决于先前的输出。具体而言，如图1（b）所示，当前处理的信号s^(t) 中存在的失真/泄露将会影响下一个循环d(t+Δt)中麦克风接受到的反馈信号。理想情况下，我们应该通过在样本层面更新训练参数来以自适应的方式训练深度学习模型。然而，这需要大量的计算，在实际应用中很难实现。

因此，我们提议Deep AHS使用教师强制学习[21][22]来训练一个用于啸叫抑制的模型。假设模型一旦经过适当训练后，它应该衰减麦克风中的反馈信号，只向扬声器发送目标语音。在模型训练的过程中，我们将目标语音s(t) 作为教师信号，在网络的后续计算中去替换实际的输出s^(t)，如图1（b）所示。

通过使用教师强制学习，反馈信号d(t) 是仅受 s(t) 影响的确定的信号，并且在方程(2)中，多个回放信号的重复求和可以简化一次的回放。在模型下训练的对应麦克风信号可以被写为：

$$y(t) = s(t) + n(t) + NL[s(t - \Delta t) \cdot G] * h(t) \tag{3}$$

教师强制学习期间的麦克风信号是目标信号、背景噪声和确定的一次性回放信号的混合。因此，整个问题可以表述为语音分离问题。以教师强制学习的方式训练 Deep AHS不仅简化了整体问题，而且能够减少AHS自适应过程中引入的不确定性，产生鲁棒的啸声抑制解决方案。

3.2. 不同的训练策略

本文探讨了不同的训练策略。最直接的方法是直接使用 (3) 中的麦克风信号作为输入，并将相应的 s(t) 设置为训练目标。我们将这种训练策略命名为不使用参考信号的训练模型（“w/o Ref”）。

一种更合适的方法是从输入中提取更多信息，并在模型训练过程中将其用作参考信号。我们建议使用延迟的麦克风信号作为附加输入（参考信号），并在初始阶段估计延迟量。考虑到回放信号可以被视为s（t）的延迟、缩放、非线性版本，使用延迟的麦克风信号有助于模型更好地区分目标信号和回放。我们将这种训练策略命名为“w Ref”。

此外，考虑到在s^ 中总是存在漏损量，在离线训练和实时应用中总是会存在一种不匹配。为了克服不匹配并更好地接近真实环境，我们提出了另一种策略，该策略通过使用预处理信号对模型进行微调来实现，称为“微调”。这样的话，离线训练的麦克风信号便是(3)的修改版本：

$$y'(t) = s(t) + d'(t) + n(t) \tag{4}$$

其中d′（t）是使用估计目标s^（t−Δt）生成的失真反馈信号。具体来说，我们使用预训练模型对所有训练数据进行预处理，然后通过音频系统发送增强的输出，

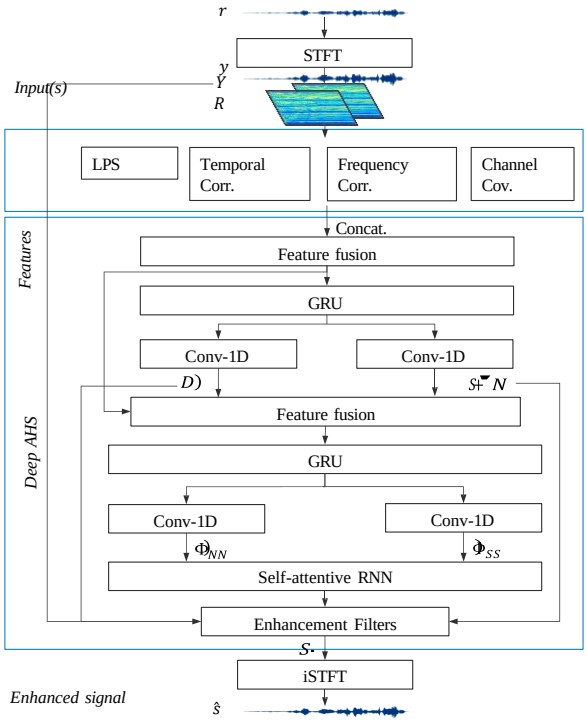

图. 2. Deep AHS 抑制啸叫的网络结构.

以得到相应的反馈信号d′（t）。最后，我们使用y′（t）作为输入对模型进行微调。鉴于模型在训练过程中出现了失真，预计前面提到的不匹配将略有减少。

3.3. 网络结构的细节

使用方法的示意图如图2所示，首先，以16K Hz采样的麦克风信号y(t)和参考信号r(t)被划分为32ms和16ms大小的移动帧。对每一帧使用512采样点大小的短时傅里叶变换（STFT），得到频域输入Y和R。除了正则化对数功率谱（LPS）外，我们还分别计算麦克风和参考信号的时间帧和频率单元的相关矩阵，将其作为输入特征。这些特征用于捕获输入信号的时间和频率特性，并有助于区分啸叫和音调成分。输入信号的信道协方差被计算为另一输入特征，以说明它们之间的互相关性。这些特征的关联用于模型训练，一个线性层，用于特征融合。

该网络由三部分组成，第一部分采用一个包含257个隐藏单元的门控循环单元（GRU）层和两个一维卷积层，来估计出用于反馈抑制和反馈估计的复值滤波器。然后通过深度滤波[20]将估计量应用于输入信号[20]，以获得相应的中间输出，表示为Y和R。

然后，这些中间输出将被用作附加输入并将其LPS与与第一部分的融合特征一起串联融合，以作为另一GRU层的输入。我们将Y，Y˜和R˜视作一个三通道输入，并对每个输入通道做两次一维卷积，用于估计其中的播放/噪音和目标语音成分。计算出反馈/噪音的协方差矩阵Φˆ N N 和目标语音的协方差矩阵Φˆ SS ，并将其级联作为第三部分的输入。

第三部分是基于多通道信号处理思想的增强滤波估计。我们训练一个自注意机制的RNN来估计一个三通道语音增强滤波器$\mathbf{W} \in \mathbb{C}^{F\times T\times 3}$然后，将这些滤波器应用于输入信道（Y、Y和R）以获得增强的目标语音Sˆ。最后利用逆STFT（i STFT）得到波形sˆ。有关功能设计和网络结构的详细信息，请参见[19]。

模型训练的损失函数被定义为时域的尺度不变信噪比（SI-SDR）[23]和 频域频谱下的平均绝对误差（MAE）的组合：

$$\text{Loss} = -\text{SI-SDR}(\hat{s}, s) + \lambda\,\text{MAE}(|\hat{S}|, |S|) \tag{5}$$

其 中 的λ被设置为10000，以平衡两个损失的值的范围。

3.4. 循环模式下的流推理

算法 1 流推理过程

procedure STREAMING$((y, r) \rightarrow \hat{s})$ ▷ r: reference signal
  Initialization: $\mathbf{y}_{\text{buffer}}, \mathbf{r}_{\text{buffer}}$, load DNN model: $f(\cdot)$

  Parameters: Delay: Δt, gain: G, nonlinearity: $\text{NL}(\cdot)$
  while $m \le M$ **do** ▷ M is the total number of frames
    $\hat{s}_m \leftarrow f(\mathbf{y}_{\text{buffer}}, \mathbf{r}_{\text{buffer}})$ ▷ Get output at frame m
    $\hat{s} \leftarrow \hat{s}_m$ ▷ Save to final output
    $x_{m+1} \leftarrow \text{Delayed } \hat{s}_m \cdot G$ ▷ Get loudspeaker signal
    $d_{m+1} \leftarrow \text{NL}(x_{m+1}) * h$ ▷ Get next playback
    $\mathbf{y}_{\text{buffer}} \leftarrow d_{m+1} + s_{m+1} + n_{m+1}$ ▷ Update input
    $\mathbf{r}_{\text{buffer}} \leftarrow \mathbf{y}_{\text{buffer}}$ ▷ Update reference signal
  end while
  return $\hat{s}$ ▷ The streaming output is $\hat{s}$
end procedure

因为Deep AHS的离线训练和推理阶段总是不匹配的。因此我们实现了一种流式推理方法，在该方法中，处理过程的输出被循环回并在随后的时间步长中添加到输入，以在真实和循环模式下评估Deep AHS的性能。该流式推理的详细信息如算法1所示。

4. 实验组织

4.1. 数据准备

我们使用AISHELL-2[24] 模拟了具有反馈和背景噪声的单通道数据集。使用图像方法[25]生成总数为10k的房间脉冲响应（RIR），其随机房间特性和混响时间（RT60）范围为0到0.6s。每个RIR由近端扬声器、扬声器和背景噪声位置的RIR组成。在数据生成期间，使用在[0.1，0.5]秒的范围内随机生成的系统延迟Δt，利用随机选择的RIR集来生成目标语音s及其对应的一次性回放信号d。使用硬限幅和Sigmoid函数[12]将放大器和扬声器引入的非线性失真模拟为非线性的饱和类型。用于离线训练的麦克风信号创建为混合信号，

表 1. 反馈衰减模型的离线评估

Models	SI-SDR			PESQ		
SPR	-5	0	5	-5	0	5
unprocessed: y	-4.29	0.72	5.70	1.66	2.06	2.45
w/o Ref	6.78	9.88	13.02	2.61	2.90	3.17
w Ref	9.19	12.12	15.22	2.81	3.09	3.33
unprocessed: y′	-3.01	1.47	5.98	1.83	2.24	2.58
w Ref, fine-tuned	10.10	13.96	18.06	3.05	3.37	3.60

其中信号回放比（SPR）从$[-15, 20]$dB中随机选择，信噪比（SNR）从-10 dB到40 dB中随机获得。总共生成了10k、0.3k和0.5k的语音数据集，分别用于训练、验证和测试。测试数据是使用从训练和验证数据生成的不同的语音和RIR。该模型训练了30个循环，批量大小为20。

4.2. 方法评估

通过离线评估和流式推理两种不同的方式对所提方法的性能进行评估。离线评估使用（3）中生成的信号作为输入来评估反馈衰减性能。SI-SDR和语音质量感知评估（PESQ）[26]用于评估回放衰减程度和目标语音质量。值越大表示性能越好。

对于流式推断，我们使用算法1中描述的流式方法生成增强信号，其中麦克风信号在考虑泄漏/失真的情况下以循环模式更新。该推理方法模拟了实际应用中啸叫的产生情况，可用于实时显示啸叫抑制性能。

5. 实验结果

5.1. 反馈衰减离线评估

我们首先以离线方式评估所提出的方案。具体来说，测试用麦克风信号的产生方式与模型训练时相同，在不同SPR水平和30 dB SNR下的测试结果如表1所示。实验结果表明，该方法仅以传声器信号作为输入，有效地衰减了反馈信号。使用延迟麦克风信号作为参考信号有助于进一步提高整体性能。值得注意的是，表1所示的结果仅表明，该方法能够提取目标语音，并能抑制微型电话录音中的一次性回放。在第5.2节中，我们将展示使用流式推理获得的结果，以显示其在实时实现过程中对啸叫抑制的性能。

此外，使用微调模型获得的结果见表1的最后两行。由于精调模型是使用预处理信号进行测试的，因此不适合用这种评估方式直接将精调模型与其他的两种模型进行比较。然而，在流式推理期间进行这样的比较是公平的，因为在流式推理期间以相同的方式处理具有和不具有微调的模型。对于微调后的模型，不需要进行预处理。

表 **2.** 用于抑制啸叫的流式评估的PESQ。

Playback level	no AHS	NF	AFC	w/o Ref	w Ref	w Ref, Fine-tuned
Soft	2.45	2.50	2.60	2.74	2.95	3.02
Moderate	1.78	1.85	2.22	2.27	2.68	2.74
Severe	1.63	1.79	2.13	2.07	2.53	2.56

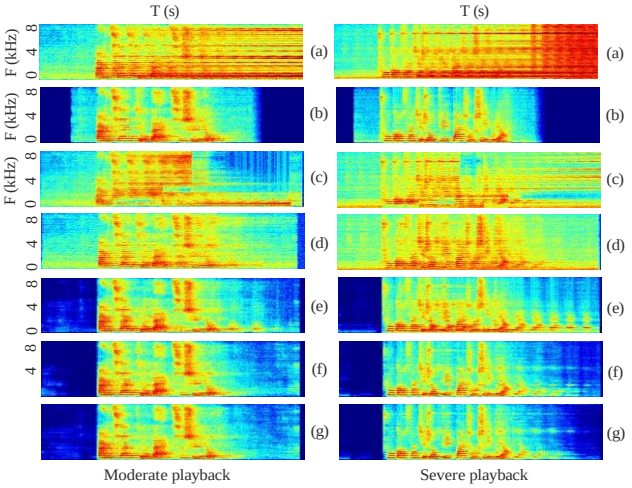

图. 3. 不同方法抑制啸叫的频谱图
有中度和重度的啸叫. 对应每个面板: (a) no AHS, (b) target signal, (c) NF, (d) AFC, (e) w/o Ref, (f) w Ref, (g) w Ref, fine-tuned.

5.2. 抑制啸叫的流推理

本部分评估了用于实时啸叫抑制的Deep AHS的性能，并使用算法1中描述的流推理方法生成输出。我们通过在流式播放阶段逐渐增加放大增益G，生成了三个软、中、重度播放的测试场景，结果如表2所示。为了更好地显示啸叫抑制性能，两个测试样品的频谱图如图3所示。使用陷波滤波器[6]和基于自适应反馈对消的AHS（使用Kalman滤波器[27]）进行比较。实验结果表明，该方法能够在参考信号的情况下抑制啸叫和深度AHS模型，优于传统AHS方法。微调后的模型获得了最佳的整体性能。

6. 结论

在本文中，我们首次提出了一种深度学习方法来抑制声学啸叫。所提出的方法通过使用基于注意力机制的递归神经网络，从麦克风录音中提取目标信号并设计适当的特征来解决AHS问题。基于教师强制学习的理念，Deep AHS模型使用教师信号进行离线训练，并以离线和流式两种方式进行评估，以显示其抑制啸叫的性能。我们研究了多种训练策略，不同场景下的评估结果表明了所提出的啸叫抑制方法的有效性。未来的工作包括Deep AHS的硬件设备实现，考虑具有声啸和声回波的声学场景，和将提出的方法扩展到多通道扩音系统中。

7. 参考文献

[1] Richard V Waterhouse, "Theory of howlback in reverberant rooms," *The Journal of the Acoustical Society of America*, vol. 37, no. 5, pp. 921–923, 1965.

[2] Toon Van Waterschoot and Marc Moonen, "Fifty years of acoustic feedback control: State of the art and future challenges," *Proceedings of the IEEE*, vol. 99, no. 2, pp. 288–327, 2010.

[3] Jeremy Agnew, "Acoustic feedback and other audible artifacts in hearing aids," *Trends in Amplification*, vol. 1, no. 2, pp. 45–82, 1996.

[4] Manfred R Schroeder, "Improvement of acoustic-feedback stability by frequency shifting," *The Journal of the Acoustical Society of America*, vol. 36, no. 9, pp. 1718–1724, 1964.

[5] Edgar Berdahl and Dan Harris, "Frequency shifting for acoustic howling suppression," in *Proceedings of the 13th International Conference on Digital Audio Effects*, *Graz*, *Austria*, 2010, vol. 610.

[6] W Loetwassana, R Punchalard, A Lorsawatsiri, J Koseeyaporn, and P Wardkein, "Adaptive howling suppressor in an audio amplifier system," in *2007 Asia-Pacific Conference on Communications*. IEEE, 2007, pp. 445–448.

[7] Pepe Gil-Cacho, Toon Van Waterschoot, Marc Moonen, and Søren Holdt Jensen, "Regularized adaptive notch filters for acoustic howling suppression," in *2009 17th European Signal Processing Conference*. IEEE, 2009, pp. 2574–2578.

[8] Toon van Waterschoot and Marc Moonen, "Comparative evaluation of howling detection criteria in notch-filter-based howling suppression," *Journal of the audio engineering society*, vol. 58, no. 11, pp. 923–940, 2010.

[9] Harry Alfonso L Joson, Futoshi Asano, Yo¯iti Suzuki, and Toshio Sone, "Adaptive feedback cancellation with frequency compression for hearing aids," *The Journal of the Acoustical Society of America*, vol. 94, no. 6, pp. 3248–3254, 1993.

[10] Jae-Won Lee and Seung Ho Choi, "Improvements in howling margin using phase dispersion," in *International Conference on Future Generation Communication and Networking*. Springer, 2011, pp. 154–161.

[11] Guozheng Wang, Quanli Liu, and Wei Wang, "Adaptive feedback cancellation with prediction error method and howling suppression in train public address system," *Signal Processing*, vol. 167, pp. 107279, 2020.

[12] Hao Zhang and De Liang Wang, "Deep learning for acoustic echo cancellation in noisy and double-talk scenarios," *Training*, vol. 161, no. 2, pp. 322, 2018.

[13] Hao Zhang, Ke Tan, and De Liang Wang, "Deep learning for joint acoustic echo and noise cancellation with nonlinear distortions.," in *INTERSPEECH*, 2019, pp. 4255–4259.

[14] Shimin Zhang, Yuxiang Kong, Shubo Lv, Yanxin Hu, and Lei Xie, "FT-LSTM based complex network for joint acoustic echo cancellation and speech enhancement," *arXiv preprint arXiv:2106.07577*, 2021.

[15] Ross Cutler, Ando Saabas, Tanel Parnamaa, Marju Purin, Hannes Gamper, Sebastian Braun, Karsten Sørensen, and Robert Aichner, "ICASSP 2022 acoustic echo cancellation challenge," in *2022 IEEE International Conference on Acoustics*, *Speech and Signal Processing (ICASSP)*. IEEE, 2022, pp. 9107–9111.

[16] Hao Zhang and De Liang Wang, "Neural cascade architecture for multi-channel acoustic echo suppression," *IEEE/ACM Transactions on Audio*, *Speech*, *and Language Processing*, vol. 30, pp. 2326–2336, 2022.

[17] Zhipeng Chen, Yiya Hao, Yaobin Chen, Gong Chen, and Liang Ruan, "A neural network-based howling detection method for real-time communication applications," in *2022 IEEE International Conference on Acoustics*, *Speech and Signal Processing (ICASSP)*. IEEE, 2022, pp. 206–210.

[18] Huaguo Gan, Gaoyong Luo, Yaqing Luo, and Wenbin Luo, "Howling noise cancellation in time–frequency domain by deep neural networks," in *Proceedings of Sixth International Congress on Information and Communication Technology*. Springer, 2022, pp. 319–332.

[19] Meng Yu, Yong Xu, Chunlei Zhang, Shi-Xiong Zhang, and Dong Yu, "Neuralecho: A self-attentive recurrent neural network for unified acoustic echo suppression and speech enhancement," *arXiv preprint arXiv:2205.10401*, 2022.

[20] Wolfgang Mack and Emanue¨l AP Habets, "Deep filtering: Signal extraction and reconstruction using complex time-frequency filters," *IEEE Signal Processing Letters*, vol. 27, pp. 61–65, 2019.

[21] Ronald J Williams and David Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.

[22] Alex M Lamb, Anirudh Goyal ALIAS PARTH GOYAL, Ying Zhang, Saizheng Zhang, Aaron C Courville, and Yoshua Bengio, "Professor forcing: A new algorithm for training recurrent networks," *Advances in neural information processing systems*, vol. 29, 2016.

[23] Jonathan Le Roux, Scott Wisdom, Hakan Erdogan, and John R Hershey, "SDR–half-baked or well done?," in *2019 IEEE International Conference on Acoustics*, *Speech and Signal Processing (ICASSP)*. IEEE, 2019, pp. 626–630.

[24] Jiayu Du, Xingyu Na, Xuechen Liu, and Hui Bu, "Aishell-2: Transforming mandarin asr research into industrial scale," *arXiv preprint arXiv:1808.10583*, 2018.

[25] Jont B Allen and David A Berkley, "Image method for efficiently simulating small-room acoustics," *The Journal of the Acoustical Society of America*, vol. 65, no. 4, pp. 943–950, 1979.

[26] Antony W Rix, John G Beerends, Michael P Hollier, and Andries P Hekstra, "Perceptual evaluation of speech quality (PESQ)-a new method for speech quality assessment of telephone networks and codecs," in *2001 IEEE International Conference on Acoustics*, *Speech*, *and Signal Processing (ICASSP)*. IEEE, 2001, vol. 2, pp. 749–752.

[27] Felix Albu, Linh TT Tran, and Sven Nordholm, "The hybrid simplified kalman filter for adaptive feedback cancellation," in *2018 International Conference on Communications (COMM)*. IEEE, 2018, pp. 45–50.